

자료구조 (Data Structure)

7주차: 정렬

오늘의 목차

- 정렬 알고리즘의 필요성과 정의
- 정렬 알고리즘의 종류
 - heap sort와 selection sort
 - quick sort와 insertion sort
 - merge sort
 - counting sort

정렬 알고리즘의 필요성

- 데이터를 정렬하는 이유는?
 - 유저의 필요
 - 프로그램 성능 향상

정렬의 정의

- 데이터를 특정 기준에 따라 순서대로 배열하는 과정
- 오름차순과 내림차순 정렬

HEAP_SORT

- 힙 자료구조를 이용한 정렬 방법

HEAP_SORT 과정

1. 배열로부터 최대 힙 생성
2. 루트 노드를 제거하고 마지막 노드와 교체
3. 나머지 노드들에 대해 힙 속성 회복
4. 2~3 과정을 반복하여 정렬 완료

HEAP_SORT 시각화

- 예시: [5, 3, 2, 7, 1] 정렬 과정
 - 최대 힙 생성: [7, 5, 2, 3, 1]
 - 1회전: [5, 3, 2, 1] + [7]
 - 2회전: [3, 1, 2] + [5, 7]
 - 3회전: [2, 1] + [3, 5, 7]
 - 4회전: [1] + [2, 3, 5, 7]
 - 5회전: [] + [1, 2, 3, 5, 7]

HEAP_SORT

함수 HEAP_SORT(배열리스트 L):

- 힙 heap = 새 최대힙(L->data, L->size)
- 반복: i는 L의 전체 인덱스를 거꾸로
L->data[i] = HEAP_POP(heap)
- 삭제: heap

HEAP_SORT의 시간 복잡도

최대 힙 생성시 시간복잡도 (perfect binary tree):

- 트리의 끝 층 노드(leaf): 비교 0회, 교환 0회
- 끝의 한층 위 노드(leaf 위): 비교 2회, 교환 1회
- ... 루트 노드: 비교 $2h$ 회, 교환 h 회

- 비교 총 합: $2 \times 0 \times \frac{n}{2} + 2 \times 1 \times \frac{n}{2^2} + \dots + 2 \times h \times \frac{n}{2^{h+1}}$

$$= n \sum_{i=0}^h \frac{1}{2^i}$$

$$\approx 2n$$

HEAP_SORT의 시간 복잡도

HEAP_POP 수행시 시간복잡도 (perfect binary tree):

- 트리 높이가 h 이면: 비교 $2h$ 회, 교환 h 회
- ... 높이가 1이면: 비교 2 회, 교환 1 회
- 비교 총 합: $2 \times h \times \frac{n}{2} + 2 \times (h - 1) \times \frac{n}{2^2} + \dots$

$$\begin{aligned} &= \sum_{i=0}^{h-1} \left((h - i) \frac{n}{2^i} \right) \\ &= hn \sum_{i=0}^{h-1} \frac{1}{2^i} - n \sum_{i=0}^{h-1} \frac{i}{2^i} \\ &= 2hn - 2n \\ &\approx 2n \log n \end{aligned}$$

HEAP_SORT의 시간 복잡도

HEAP_SORT의 시간복잡도:

- 비교 횟수 $\approx 2n \log n$
- 교환 횟수 $\approx n \log n$
- $O(n \log n)$

SELECTION_SORT

- HEAP_SORT와 같은 전략
 - 정렬 전 구간의 최대값을 맨 뒤로 이동
- 최대값을 찾을 때 모든 값을 확인해서 느림

SELECTION_SORT 과정

1. 배열에서 최대값 찾기
2. 최대값을 맨 뒤의 원소와 교체
3. 두번째 최대값을 뒤에서 두번째 원소와 교체
4. ... 반복

SELECTION_SORT 시각화

- 예시: [5, 3, 2, 7, 1] 정렬 과정

1회전: [5, 3, 2, 1, 7]

2회전: [1, 3, 2, 5, 7]

3회전: [1, 2, 3, 5, 7]

4회전: [1, 2, 3, 5, 7]

5회전: [1, 2, 3, 5, 7]

SELECTION_SORT

함수 SELECTION_SORT(리스트 L, 인덱스 lo, 인덱스 hi):

- 반복: pos는 hi부터 lo까지

max_i = pos

반복: i는 pos부터 lo까지

만약: $L \rightarrow \text{data}[i] > L \rightarrow \text{data}[\text{max_i}]$ 면

max_i = i

SWAP(L, max_i, pos)

SELECTION_SORT

함수 SWAP(리스트 L, 인덱스 i, 인덱스 j):

- `tmp = L->data[i]`
- `L->data[i] = L->data[j]`
- `L->data[j] = tmp`

SELECTION_SORT의 시간 복잡도

비교 횟수:

- 최대값을 찾을 때: $n - 1$
- 두번째 최대값을 찾을 때: $n - 2$
- ...
- 총합: $(n - 1) + (n - 2) + \dots = \frac{n(n-1)}{2} = O(n^2)$

교환 횟수:

- $n - 1$ 번

HEAP_SORT와 SELECTION_SORT 비교

- 시간 복잡도
 - HEAP_SORT: $O(n \log n)$
 - SELECTION_SORT: $O(n^2)$
- 공간 복잡도
 - 둘 다: $O(1)$
- HEAP_SORT는 빅데이터에서 더 나은 성능을 제공

QUICK_SORT

- 가장 빠른 정렬 알고리즘
- 기준값을 정해서 작은 값들과 큰 값들을 분리, 재배치

QUICK_SORT 과정

1. 기준값 선택 (제일 끝 값)
2. 기준값을 기준으로 작은 값들과 큰 값들로 분할
3. 작은 값들과 큰 값들에 대해 1~2 과정을 반복

QUICK_SORT 시각화

- 예시: [5, 3, 2, 7, 1] 정렬 과정

기준값 1 선택: [1], [5, 3, 2, 7]

기준값 7 선택: [1], [5, 3, 2], [7]

기준값 2 선택: [1], [2], [5, 3], [7]

기준값 5 선택: [1], [2], [3], [5], [7]

최종 정렬 결과: [1, 2, 3, 5, 7]

QUICK_SORT

함수 QSORT(리스트 L, 인덱스 lo, 인덱스 hi):

- 만약: $lo < hi$ 이면

$pivot = PARTITION(L, lo, hi)$

$QSORT(L, lo, pivot - 1)$

$QSORT(L, pivot + 1, hi)$

QUICK_SORT

함수 PARTITION(리스트 L, 인덱스 lo, 인덱스 hi):

- pivot_data = L->data[hi]
- left_rear = lo // pivot이하 그룹 끝 + 1
- 반복: i는 lo부터 hi - 1까지
 만약: L->data[i] <= pivot_data이면
 SWAP(L, left_rear, i)
 left_rear += 1
- SWAP(L, left_rear, hi) // 기준점 위치
- 반환: left_rear

QUICK_SORT의 시간 복잡도

QUICK_SORT의 평균 비교 횟수 (왼쪽이 k 개일 때):

- $C(n) = n - 1 + C(k) + C(n - k - 1)$

$$\text{평균} = n - 1 + \frac{2}{n} \sum C(k)$$

$$nC(n) = n(n - 1) + 2 \sum C(k)$$

$$(n - 1)C(n - 1) = (n - 1)(n - 2) + 2 \sum C(k)$$

$$nC(n) - (n + 1)C(n - 1) = 2(n - 1)$$

$$\frac{C(n)}{n+1} = \frac{C(n-1)}{n} + \frac{2(n-1)}{n(n+1)} \approx \frac{C(n-1)}{n} + \frac{2}{n} - \frac{4}{n(n+1)} \approx 2 \ln n$$

$$C(n) \approx 2n \ln n = O(n \log n)$$

- 평균 교환 횟수는 $C(n)/2 \approx n \ln n$

QUICK_SORT의 시간 복잡도

QUICK_SORT의 최악 비교 횟수 (왼쪽이 0개로 나뉘는 때):

- $$\begin{aligned} C(n) &= (n - 1) + C(n - 1) \\ &= (n - 1) + (n - 2) + C(n - 2) \\ &= (n - 1) + (n - 2) + \dots \\ &= \frac{(n-1)n}{2} \\ &= O(n^2) \end{aligned}$$

INSERTION_SORT

- 정렬된 부분의 적절한 위치로 데이터를 이동해간다

INSERTION_SORT 과정

왼쪽부터 정렬해나가는 경우:

1. 정렬되지 않은 부분의 왼쪽 원소에 대해서,
정렬된 부분에서 적절한 위치 찾기
2. 찾은 위치에 추가하여 정렬된 부분 확장
3. ... 반복

INSERTION_SORT 시각화

- 예시: [5, 3, 2, 7, 1] 정렬 과정

1회전: [3, 5, 2, 1, 7]

2회전: [2, 3, 5, 1, 7]

3회전: [1, 2, 3, 5, 7]

4회전: [1, 2, 3, 5, 7]

INSERTION_SORT

함수 INSERTION_SORT(리스트 L, 인덱스 lo, 인덱스 hi):

- 반복: rear는 lo부터 hi까지

value = L->data[rear] // 이동할 데이터

i = rear // 데이터를 이동할 위치

반복: $i > lo$ 이고, $L->data[i - 1] > value$ 인 동안

$L->data[i] = L->data[i - 1]$

$i -= 1$

$L->data[i] = value$

INSERTION_SORT의 시간 복잡도

반복 조건 확인 횟수 (최악):

- $C_{worst}(n) = 1 + 2 + \dots + n = \frac{n(n+1)}{2} = O(n^2)$

반복 조건 확인 횟수 (평균):

- $C_{avg}(n) = \frac{C_{worst}(n)}{2} = \frac{n(n+1)}{4} = O(n^2)$

반복 조건 확인 횟수 (최선, 거의 정렬된 경우):

- $C_{best}(n) = 1 + 1 + \dots + 1 = n = O(n)$

QUICK_SORT vs HEAP_SORT

- 퀵 정렬은 단순해서 평균 실행 시간이 더 빠르다
- 힙 정렬은 최악의 경우에도 $O(n \log n)$ 을 보장한다

하이드브리드 정렬 (INTRO_SORT)

- 퀵 정렬의 평균 성능과 힙 정렬의 최악 성능 결합
- n 이 작아지면 INSERTION_SORT로 전환
- C++의 표준 정렬 함수

INTRO_SORT 과정

1. 퀵 정렬로 분할 정복 수행
2. 재귀 깊이가 일정 수준 이상일 경우 힙 정렬로 전환
3. 데이터 수가 적으면 INSERTION_SORT

INTRO_SORT 시각화

- 예시: [5, 3, 2, 7, 1] 정렬 과정
- 삽입 정렬이 실행됨
- 최종 정렬 결과: [1, 2, 3, 5, 7]

INTRO_SORT

함수 INTRO_SORT(리스트 L, 인덱스 lo, 인덱스 hi,
정수 limit):

- 만약: $hi - lo < 15$ 이면

INSERTION_SORT(L, lo, hi)

- 아니면 만약: $limit == 0$ 이면

HEAP_SORT(L, lo, hi)

- 아니면:

pivot = PARTITION(L, lo, hi)

INTRO_SORT(L, lo, pivot - 1, limit - 1)

INTRO_SORT(L, pivot + 1, hi, limit - 1)

MERGE SORT

- 반으로 나눠서 각각 정렬한 후, 정렬하며 합치는 방법

MERGE SORT 과정

1. 배열을 반으로 분할
2. 각 부분에 대해 재귀적으로 정렬
3. 정렬된 두 부분을 합침

MERGE SORT 시각화

- 예시: [5, 3, 2, 7, 1] 정렬 과정

분할: [5,3] , [2,7,1]

정렬: [3,5] , [1,2,7]

합치기: [1,2,3,5,7]

MERGE_SORT

함수 MERGE_SORT(리스트 L, 인덱스 lo, 인덱스 hi):

- 만약: $lo < hi$ 이면

$mid = (lo + hi) / 2$

MERGE_SORT(L, lo, mid)

MERGE_SORT(L, mid + 1, hi)

MERGE(L, lo, mid, hi)

함수 MERGE(리스트 L, 인덱스 lo, 인덱스 mid,
인덱스 hi):

- $\text{left_size} = \text{mid} - \text{lo} + 1$
- $\text{right_size} = \text{hi} - \text{mid}$
- $\text{left_q} = \text{새로운 큐}(\text{left_size})$
- $\text{right_q} = \text{새로운 큐}(\text{right_size})$

- 반복: i 는 lo 부터 mid 까지
 `ENQUEUE(left_q, list->data[i])`
- 반복: i 는 $mid + 1$ 부터 hi 까지
 `ENQUEUE(right_q, list->data[i])`

MERGE 3 / 4

- merged = 새로운 리스트(list->data, 0)
- 반복: !EMPTY(left_q) 그리고 !EMPTY(right_q) 일 동안

만약: FRONT(left_q) <= FRONT(right_q) 이면

ALIST_PUSH(merged, DEQUEUE(left_q))

아니면:

ALIST_PUSH(merged, DEQUEUE(right_q))

- 반복: !EMPTY(left_q)일 동안
ALIST_PUSH(merged, DEQUEUE(left_q))
- 반복: !EMPTY(right_q)일 동안
ALIST_PUSH(merged, DEQUEUE(right_q))
- 삭제: left_q, right_q, merged

MERGE_SORT의 시간 복잡도

MERGE시 시간복잡도:

- 총 길이가 k 인 두 배열을 합칠 때, 비교 k 회, 대입 $2k$ 회
- MERGE 트리 한 층에서: 비교 n 회, 대입 $2n$ 회
- MERGE 트리의 높이인 $\log n$ 번 반복

총 비교 $n \log n$ 회, 대입 $2n \log n$ 회: $O(n \log n)$

MERGE_ vs QUICK_ and HEAP_SORT

- MERGE_SORT는 값이 같은 데이터 순서가 보존된다
- 이미 정렬된 부분을 보존하며 합칠 수 있다
- MERGE시 추가 메모리 공간이 필요하다

하이드브리드 정렬(POWER_SORT)

- MERGE 트리의 왼쪽 끝에서 MERGE 해가는 형태
- 앞에서부터 정렬된 구간을 찾고, MERGE 해가는 방법
- 정렬된 구간이 짧으면 INSERTION SORT로 늘림
- 정렬된 구간들은 스택에 보관
- 파이썬 정렬 함수에서 쓰임

COUNTING_SORT

- 데이터의 개수를 세어 정렬하는 방법

COUNTING_SORT 과정

1. 데이터 개수를 세는 배열 생성 및 초기화
2. 각 원소의 개수 세기
3. 출력 배열에 정렬된 원소 배치

COUNTING_SORT 시각화

- 예시: [5, 5, 2, 2, 1] 정렬 과정
- 최대값: 5
- 카운트 배열: [0, 1, 2, 0, 0, 2]
- 최종 정렬 결과: [1, 2, 2, 5, 5]

COUNTING_SORT

함수 COUNTING_SORT(리스트 L, 정수 max_value):

- count = 새로운 배열(max_value + 1) // 0으로 초기화
- 반복: value는 L의 모든 데이터

count[value] += 1

- sorted = 새로운 리스트(L->data, 0)
- 반복: value는 0부터 max_value까지

반복: count[value]번

ALIST_PUSH(sorted, value)

- 삭제: count, sorted

COUNTING_SORT의 시간 복잡도

개수 배열 초기화의 시간복잡도:

- $O(k)$

데이터 개수 세기:

- $O(n)$

총 $O(n + k)$

- heap sort: $O(n \log n)$
- quick sort: 평균 $O(n \log n)$, 최악 $O(n^2)$
- insertion sort: 최선 $O(n)$, 평균 및 최악 $O(n^2)$
- merge sort: $O(n \log n)$
- counting sort: $O(n + k)$